TDE A - Efeito da Preparação dos Dados

Rafael João Martini

Seção 1: Experimento 1

Configuração:

Normalização = Sim;
Remoção de Outliers = Sim;
Seleção de Características = Sim;
Projeção = Não.

O conjunto foi dividido por holdout estratificado, com 2/3 das amostras para treinamento e 1/3 para teste (semente: 1).
A remoção de outliers foi feita apenas no conjunto de treinamento: em cada variável, os valores atípicos foram identificados pelo critério do boxplot (limites de 1,5 vezes o intervalo interquartil), e as amostras com ao menos um outlier foram descartadas, mantendo-se o conjunto de teste intacto.
Em seguida, aplicou-se a normalização por escore-Z, com média e desvio padrão estimados sobre o treinamento já sem outliers e depois aplicados ao teste, evitando vazamento de dados. Por fim, a seleção de características foi feita sobre a matriz de correlação do treinamento, removendo as variáveis fortemente correlacionadas (limiar de 0,95), e as mesmas variáveis foram removidas do teste. Ao final, o treinamento e o teste utilizaram 5 variáveis, das 7 originais.

Tabela 1 - Resultados do Experimento 1.

Experimento	Acurácia	Intervalo de Confiança (95% CI)	N° de Parâmetros Estimados do Modelo
QDA	92,04%	90,41% a 93,47%	41
LDA	92,91%	91,35% a 94,26%	26
Naive Bayes	92,67%	91,10% a 94,04%	21

Seção 2: Experimento 2

Configuração:

Normalização = Sim;
Remoção de Outliers = Sim;
Seleção de Características = Não;
Projeção = Não.

Foram aplicadas a remoção de outliers no treino (1,5×IQR) e a normalização por escore-Z, sem seleção de características. Treino e teste mantiveram as 7 variáveis por não ter a seleção de características.
O modelo apresentou número muito maior de parâmetros do que no experimento anterior, e teve um ganho pequeno na acurácia do QDA e LDA com leve perda na acurácia do Naive Bayes.

Tabela 2 - Resultados do Experimento 2.

Experimento	Acurácia	Intervalo de Confiança (95% CI)	N° de Parâmetros Estimados do Modelo
QDA	92,59%	91,01% a 93,97%	71
LDA	93,38%	91,87% a 94,69%	43
Naive Bayes	92,04%	90,41% a 93,47%	29

Seção 3: Experimento 3

Configuração:

Normalização = Sim;
Remoção de Outliers = Não;
Seleção de Características = Sim;
Projeção = Não.

Foram aplicadas a normalização por escore-Z e a seleção de características (correlação > 0,95), sem remoção de outliers. Treino e teste ficaram com 5 das 7 variáveis. Comparando com o experimento 1, queda em QDA e NB, aumento em LDA, porém tão pouco expressivo que se torna irrelevante para o modelo.

Tabela 3 - Resultados do Experimento 3.

Experimento	Acurácia	Intervalo de Confiança (95% CI)	N° de Parâmetros Estimados do Modelo
QDA	91,88%	90,24% a 93,33%	41
LDA	92,99%	91,44% a 94,33%	26
Naive Bayes	92,59%	91,01% a 93,97%	21

Seção 4: Experimento 4

Configuração:

Normalização = Sim;
Remoção de Outliers = Não;
Seleção de Características = Não;
Projeção = Não.

Foi aplicada apenas a normalização por escore-Z, sem remoção de outliers nem seleção de características. Treino e teste mantiveram as 7 variáveis.
O modelo apresentou um ganho de acurácia no LDA e QDA, perda em Naive Bayes e aumentou o número de parâmetros de todos os modelos por conta de não ter sido aplicada a seleção de características, obteve alguns ganhos de performance ao não remover os outliers.

Tabela 4 - Resultados do Experimento 4.

Experimento	Acurácia	Intervalo de Confiança (95% CI)	N° de Parâmetros Estimados do Modelo
QDA	92,83%	91,27% a 94,19%	71
LDA	93,46%	91,96% a 94,76%	43
Naive Bayes	91,96%	90,33% a 93,40%	29

Seção 5: Experimento 5

Configuração:

Normalização = Não;
Remoção de Outliers = Sim;
Seleção de Características = Sim;
Projeção = Não.

Foram aplicadas a remoção de outliers no treino (1,5×IQR) e a seleção de características (correlação > 0,95), sem normalização. Treino e teste ficaram com 5 das 7 variáveis. Obteve desempenho igual ao primeiro experimento, porém vale ressaltar que o Naive Bayes apresentou mais avisos de 0 probabilidade nas classes, pela normalização não feita nesta amostra, ocorrem mais underflows numéricos e prejudicam a confiabilidade do Naive Bayes.

Tabela 5 - Resultados do Experimento 5.

Experimento	Acurácia	Intervalo de Confiança (95% CI)	N° de Parâmetros Estimados do Modelo
QDA	92,04%	90,41% a 93,47%	41
LDA	92,91%	91,35% a 94,26%	26
Naive Bayes	92,67%	91,10% a 94,04%	21

Seção 6: Experimento 6

Configuração:

Normalização = Não;
Remoção de Outliers = Sim;
Seleção de Características = Não;
Projeção = Não.

Foi aplicada apenas a remoção de outliers no treino (1,5×IQR), sem normalização nem seleção de características. Treino e teste mantiveram as 7 variáveis.
Resultado igual ao experimento 2, com mais casos de underflow numérico no Naive Bayes.

Tabela 6 - Resultados do Experimento 6.

Experimento	Acurácia	Intervalo de Confiança (95% CI)	N° de Parâmetros Estimados do Modelo
QDA	92,59%	91,01% a 93,97%	71
LDA	93,38%	91,87% a 94,69%	43
Naive Bayes	92,04%	90,41% a 93,47%	29

Seção 7: Experimento 7

Configuração:

Normalização = Não;
Remoção de Outliers = Não;
Seleção de Características = Sim;
Projeção = Não.

Foi aplicada apenas a seleção de características (correlação > 0,95), sem normalização nem remoção de outliers. Treino e teste ficaram com 5 das 7 variáveis.
Resultado igual ao experimento 3, com mais casos de underflow numérico no Naive Bayes.

Tabela 7 - Resultados do Experimento 7.

Experimento	Acurácia	Intervalo de Confiança (95% CI)	N° de Parâmetros Estimados do Modelo
QDA	91,88%	90,24% a 93,33%	41
LDA	92,99%	91,44% a 94,33%	26
Naive Bayes	92,59%	91,01% a 93,97%	21

Seção 8: Experimento 8

Configuração:

Normalização = Não;
Remoção de Outliers = Não;
Seleção de Características = Não;
Projeção = Não.

Nenhum pré-processamento foi aplicado, e os dados originais foram usados diretamente. Treino e teste mantiveram as 7 variáveis.
Os resultados foram iguais aos do experimento 4, com mais casos de underflow numérico no Naive Bayes.

Tabela 8 - Resultados do Experimento 8.

Experimento	Acurácia	Intervalo de Confiança (95% CI)	N° de Parâmetros Estimados do Modelo
QDA	92,83%	91,27% a 94,19%	71
LDA	93,46%	91,96% a 94,76%	43
Naive Bayes	91,96%	90,33% a 93,40%	29

Seção 9: Experimentos com Projeção e Redução de Dimensionalidade (Exp. 9 e 10)

Para os Experimentos 9 e 10 foi escolhida a configuração do Experimento 4 (normalização = Sim, remoção de outliers = Não, seleção de características = Não), por apresentar a maior média de acurácia entre os três classificadores (92,75%) e a melhor acurácia para QDA (92,83%) e LDA (93,46%). O Experimento 8 teve resultados idênticos, mas o 4 foi preferido porque o PCA é sensível à escala das variáveis e a normalização, ajustada apenas no treinamento, é a preparação adequada antes da projeção. O PCA foi ajustado sobre o conjunto de treinamento e aplicado ao teste. No Experimento 9 foram mantidos os 7 componentes, ou seja, apenas a rotação dos dados. No Experimento 10 foram retidos 3 componentes dos 7 originais, que explicam 99,71% da variabilidade total, o que reduziu o número de parâmetros estimados em todos os modelos (QDA de 71 para 19, LDA de 43 para 13 e Naive Bayes de 29 para 13) o critério usado foi maior ou igual a 95% de variância acumulada.

Tabela 9 - Resultados do Experimento 9 (Somente Projeção).

Experimento	Acurácia	Intervalo de Confiança (95% CI)	N° de Parâmetros Estimados do Modelo
QDA	92,83%	91,27% a 94,19%	71
LDA	93,46%	91,96% a 94,76%	43
Naive Bayes	92,04%	90,41% a 93,47%	29

Tabela 10 - Resultados do Experimento 10 (Redução de Dimensionalidade).

Experimento	Acurácia	Intervalo de Confiança (95% CI)	N° de Parâmetros Estimados do Modelo
QDA	92,59%	91,01% a 93,97%	19
LDA	93,30%	91,78% a 94,62%	13
Naive Bayes	91,73%	90,07% a 93,18%	13

Seção 10: Análise Comparativa e Discussão

Impacto do pré-processamento

Normalização: Não alterou a acurácia de nenhum classificador. Isso é esperado, pois LDA, QDA e Naive Bayes gaussiano são invariantes a transformações afins das variáveis, já que a normalização só muda a escala das médias e das covariâncias, sem alterar a fronteira de decisão. A única diferença observada foi o maior número de avisos de underflow no Naive Bayes sem normalização.

Remoção de Outliers: Efeito pequeno e sem direção clara. QDA e LDA variaram menos de 0,3 ponto percentual (por exemplo, QDA foi de 92,83% no Exp. 4 para 92,59% no Exp. 2) e o Naive Bayes ganhou apenas 0,08 ponto. Como os outliers foram mantidos no teste, descartá-los apenas no treino não melhorou a generalização neste dataset.

Seleção de Atributos: Foi o fator de maior efeito, e em sentidos opostos. LDA e QDA perderam acurácia (QDA até 0,95 ponto, de 92,83% para 91,88%, e LDA cerca de 0,47), pois as variáveis correlacionadas removidas ainda carregavam alguma informação. Já o Naive Bayes ganhou 0,63 ponto, porque eliminar variáveis fortemente correlacionadas reduz a violação da hipótese de independência condicional.

Em conjunto: Como a normalização não muda nenhum resultado (Exp. 1=5, 2=6, 3=7, 4=8), apenas causa underflows no NB, o que vamos analisar é a escolha de remoção de outliers e seleção de atributos.
Os dois efeitos foram essencialmente independentes: a remoção de outliers variou a acurácia em no máximo 0,24 ponto, qualquer que fosse a seleção, enquanto a seleção de atributos alterou de 0,47 a 0,95 ponto os modelos LDA e QDA (para menos) e o Naive Bayes (para mais, +0,63), com ou sem remoção de outliers. Portanto, a seleção de atributos foi o fator dominante, e a remoção de outliers, um ajuste secundário sem efeito consistente.

A melhor combinação para LDA e QDA foi não remover outliers e nem selecionar atributos (Exp. 4 e 8), e o Naive Bayes foi melhor com seleção de atributos (Exp. 1 e 5, 92,67%). Entre as combinações, o Exp. 4 teve a maior média (92,75%) e foi o escolhido para os Exp. 9 e 10.

Efeito da Projeção e Redução de Dimensionalidade (Exp. 9 e 10)

Projeção (Exp. 9): A projeção dos dados sem redução de dimensão não alterou o desempenho de QDA e LDA, que obtiveram exatamente os mesmos resultados do Experimento 4 pois ambos são invariantes a rotações do espaço de atributos, e a fronteira de decisão permanece a mesma. O Naive Bayes teve um ganho de apenas 0,08 ponto.

Redução de dimensionalidade (Exp. 10): Reduzir de 7 para 3 componentes manteve a acurácia próxima à do Experimento 4, com diferenças dentro da sobreposição dos ICs e uma redução grande no número de parâmetros. Em comparação com a seleção de características tradicional (Experimento 3, com 5 variáveis), a redução por PCA superou QDA (92,59% contra 91,88%) e LDA (93,30% contra 92,99%) usando menos parâmetros (19 contra 41 e 13 contra 26). O Naive Bayes foi o único que ficou abaixo (91,73% contra

92,59%). Assim, a redução de dimensionalidade manteve a acurácia na maioria dos casos e foi ligeiramente superior a seleção tradicional para QDA e LDA, com um modelo mais enxuto.

Análise por classificador

O LDA foi o mais robusto, com a menor variação de acurácia entre experimentos (cerca de 0,55 ponto, contra 0,95 do QDA e 0,94 do NB) e a melhor acurácia em todos eles. Ele estima uma única matriz de covariância compartilhada (43 parâmetros com 7 variáveis), enquanto o QDA estima uma por classe (71 parâmetros) e tem maior variância, o que o torna mais sensível à mudança de dimensão. O Naive Bayes tem o menor número de parâmetros, que cresce só linearmente (4p + 1), mas depende da independência entre variáveis, por isso foi o mais afetado pela correlação e o único que se beneficiou da seleção.

Significância estatística

Os ICs de 95% têm cerca de 1,4 ponto para mais ou para menos e se sobrepõem em todos os experimentos e entre os três classificadores. Até a maior diferença observada (LDA no Exp. 4, 93,46%, contra NB no Exp. 10, 91,73%, ou seja, 1,73 ponto) ainda tem ICs sobrepostos. Assim, as diferenças entre pré-processamentos e entre modelos não são estatisticamente significativas.